

Detekcija spama pomocu klasicnih NLP metoda

TF-IDF + Logistic Regression | LSTM

Projekat iz Masinskog učenja

Marko Raskovic

Cilj: klasifikovati tekstualni mejl kao ham ili spam.

Problem i motivacija

- Spam detekcija je binarna klasifikacija teksta: ham ili spam.
- Problem je praktican: automatsko prepoznavanje neželjenih poruka.
- Skup je nebalansiran, pa accuracy nije dovoljna metrika.
- Zato pratimo precision, recall i F1 za spam klasu.

Pozitivna klasa

spam

klasa koju posebno pratimo

Negativna klasa

ham

regularni mejlovi

Skup podataka: Ling-Spam

Ukupno mejlova

2893

pre duplikata

Ham

2412

83.37%

Spam

481


16.63%

Duplikati

17

uklonjeni

Broj mejlova



Koriscena je bare verzija korpusa:

- bez lematizacije
- bez unapred uklonjenih stop reci
- fajlovi spmsg*.txt su spam, ostali su ham

Priprema i podela podataka

- Ucitavanje tekstualnih fajlova iz arhive lingspam_public.tar.gz.
- Formiranje tabele sa kolonama label i message.
- Uklanjanje duplikata pre podele podataka.
- Stratifikovana podela cuva slican odnos ham/spam u svakor

Podela 70 / 15 / 15

Skup	Ukupno	Ham	Spam
Trening	2013	1685	328
Validacija	431	361	70
Test	432	362	70

Zasto ova dva modela?

TF-IDF + Logistic Regression

- brz, jednostavan i lako objasnjiv klasicni NLP pristup
- dobar za tekstualne zadatke sa malo podataka
- hiperparametri: min_df i C


LSTM

- rekurentni model koji cita tekst kao niz reci
- ispunjava zahtev za RNN/LSTM/transformer model
- hiperparametri: max_words, epochs, embedding_dim, lstm_dim

Ideja poredjenja: klasicni model kao jak baseline, LSTM kao sekvencijalni model koji uci redosled reci.

TF-IDF: metrike po konfiguraciji

Na x-osi su brojevi konfiguracija; ispod grafika je mapa broj -> hiperparametri.




1 = min_df=2, C=0.5; 2 = min_df=2, C=1; 3 = min_df=2, C=2; 4 = min_df=2, C=5; 5 = min_df=5, C=0.5; 6 = min_df=5, C=1; 7 = min_df=5, C=2; 8 = min_df=5, C=5; 9 = min_df=10, C=0.5; 10 = min_df=10, C=1; 11 = min_df=10, C=2; 12 = min_df=10, C=5

Napomena: sve proverene TF-IDF konfiguracije daju isti rezultat na validacionom skupu, sto ukazuje na stabilnost modela.

LSTM: metrike po konfiguraciji

Na x-osi su brojevi konfiguracija; ispod grafika je mapa broj -> hiperparametri.

Precision, recall i F1 za spam klasu



1 = words=5000, ep=20, emb/lstm=64/64; 2 = words=5000, ep=16, emb/lstm=64/64; 3 = words=5000, ep=8, emb/lstm=64/64; 4 = words=5000, ep=20, emb/lstm=128/128; 5 = words=5000, ep=12, emb/lstm=64/64; 6 = words=5000, ep=12, emb/lstm=128/128; 7 = words=3000, ep=8, emb/lstm=64/64; 8 = words=5000, ep=16, emb/lstm=128/128; 9 = words=1000, ep=8, emb/lstm=32/32


Najbolji kandidat prema F1 meri za spam: words=5000, epochs=20, embedding_dim=64, lstm_dim=64.

Evaluacija i izbor hiperparametara

- Trening skup sluzi za učenje parametara modela.
- Validacioni skup sluzi za izbor hiperparametara i najboljeg kandidata.
- Test skup se koristi tek na kraju, za finalnu procenu.
- Glavne metrike: precision, recall i F1 za spam klasu.

Model	Skup	Precision	Recall	F1
TF-IDF + LogReg	Validacija	0.99	0.99	0.99
TF-IDF + LogReg	Test	0.99	0.96	0.97
LSTM	Validacija	0.98	0.91	0.95
LSTM	Test	0.94	0.90	0.92

Poredjenje rezultata



Zaključak: TF-IDF je stabilniji i brzi; LSTM takodje radi dobro, ali je složeniji i osetljiviji na hiperparametre.

Zaključak i literatura

- Ling-Spam je nebalansiran tekstualni skup, pa se fokus stavlja na spam metrike.
- TF-IDF + Logistic Regression daje najbolji odnos jednostavnosti, brzine i kvaliteta.
- LSTM pokazuje kako se tekst može tretirati kao sekvenca reči.
- Test skup je sačuvan za kraj, kako bi finalna procena bila postena.

Literatura:

Ling-Spam corpus; scikit-learn dokumentacija; PyTorch dokumentacija; materijali sa vezbi.