

Detekcija spama pomocu klasicnih NLP metoda

TF-IDF ♦ Logistic Regression | LSTM

Projekat iz Masinskog učenja

Marko Raskovic

Cilj: klasifikovati tekstualni mejl kao ham ili spam.

Problem i motivacija

- Spam detekcija je binarna klasifikacija teksta: ham ili spam.
- Problem je praktican: automatsko prepoznavanje neželjenih poruka.
- Skup je nebalansiran, pa accuracy nije dovoljna metrika.
- Zato pratimo precision, recall i F1 za spam klasu.

Pozitivna klasa

spam

klasa koju posebno pratimo

Negativna klasa

ham

regularni mejlovi

Skup podataka: Ling-Spam

Ukupno mejlova

2893
pre duplikata

Ham

2412
83.37%

Spam


481
16.63%

Duplikati

17
uklonjeni

Broj mejlova

481;
17%



2412;
83%

■ ham
■ spam

Koriscena je bare verzija korpusa:

- bez lematizacije
- bez unapred uklonjenih stop reci
- fajlovi spmsg*.txt su spam, ostali su ham

Priprema i podela podataka

- Ucitavanje tekstualnih fajlova iz arhive lingspam_public.tar.gz.
- Formiranje tabele sa kolonama label i message.
- Uklanjanje duplikata pre podele podataka.
- Stratifikovana podela cuva slican odnos ham/spam u svakom sk

Podela 70 / 15 / 15

Skup	Ukupno	Ham	Spam
Trening	2013	1685	328
Validacija	431	361	70
Test	432	362	70

Zasto ova dva modela?

TF-IDF ♦ Logistic Regression

- brz, jednostavan i lako objasnjiv klasicni NLP pristup
- dobar za tekstualne zadatke sa malo podataka
- hiperparametri: min_df i C


LSTM

- rekurentni model koji cita tekst kao niz reci
- ispunjava zahtev za RNN/LSTM/transformer model
- hiperparametri: max_words, epochs, embedding_dim, lstm_dim

Ideja poredjenja: klasicni model kao jak baseline, LSTM kao sekvencijalni model koji uci redosled reci.

TF-IDF: metrike po konfiguraciji

Na x-osi su brojevi konfiguracija; ispod grafika je mapa broj -> hiperparametri.



1 = min_df=2, C=0.5; 2 = min_df=2, C=1; 3 = min_df=2, C=2; 4 = min_df=2, C=5; 5 = min_df=5, C=0.5; 6 = min_df=5, C=1; 7 = min_df=5, C=2; 8 = min_df=5, C=5; 9 = min_df=10, C=0.5; 10 = min_df=10, C=1; 11 = min_df=10, C=2; 12 = min_df=10, C=5

Napomena: sve proverene TF-IDF konfiguracije daju isti rezultat na validacionom skupu, sto ukazuje na stabilnost modela.

Jupyter kod: TF-IDF grafik

Visine stubova dolaze iz precision, recall i F1 kolona tabele rezultata, izracunatih na validacionom skupu.

```
python


# Kolone su izracunate iz y_validation i predictions.
metric_columns = ["spam_precision", "spam_recall", "spam_f1"]
plot_data = results_table.reset_index(drop=True)
plot_data.index = range(1, len(plot_data) + 1)

ax = plot_data[metric_columns].plot(
    kind="bar", figsize=(11, 5), ylim=(0.90, 1.00),
    color=["tomato", "seagreen", "steelblue"],
)
ax.set_title("TF-IDF: metrike po konfiguraciji")
ax.set_xlabel("Broj konfiguracije")
ax.set_ylabel("Vrednost na validation skupu")
ax.legend(["precision", "recall", "F1"])
plt.tight_layout()
plt.show()
```

Granice y-ose 0.90-1.00 naglasavaju male razlike izmedju veoma dobrih TF-IDF rezultata.

LSTM: metrike po konfiguraciji

Na x-osi su brojevi konfiguracija; ispod grafika je mapa broj -> hiperparametri.



1 = words=5000, ep=20, emb/lstm=64/64; 2 = words=5000, ep=16, emb/lstm=64/64; 3 = words=5000, ep=8, emb/lstm=64/64; 4 = words=5000, ep=20, emb/lstm=128/128; 5 = words=5000, ep=12, emb/lstm=64/64; 6 = words=5000, ep=12, emb/lstm=128/128; 7 = words=3000, ep=8, emb/lstm=64/64; 8 = words=5000, ep=16, emb/lstm=128/128; 9 = words=1000, ep=8, emb/lstm=32/32

Najbolji kandidat prema F1 meri za spam: words=5000, epochs=20, embedding_dim=64, lstm_dim=64.

Jupyter kod: LSTM grafik

Visine stubova dolaze iz precision, recall i F1 kolona tabele rezultata, izracunatih na validacionom skupu.

```
python

# Kolone su izracunate iz real_labels i predicted_labels.
metric_columns = ["spam_precision", "spam_recall", "spam_f1"]
plot_data = results_table.reset_index(drop=True)
plot_data.index = range(1, len(plot_data) + 1)



ax = plot_data[metric_columns].plot(
    kind="bar", figsize=(11, 5), ylim=(0, 1),
    color=["tomato", "seagreen", "steelblue"],
)
ax.set_title("LSTM: metrike po konfiguraciji")
ax.set_xlabel("Broj konfiguracije")
ax.set_ylabel("Vrednost na validation skupu")
ax.legend(["precision", "recall", "F1"])
plt.tight_layout()
plt.show()
```

Numerisanje konfiguracija cuva grafik citljivim, dok se hiperparametri prikazuju u tabeli ispod celije.

LSTM: greska i F1 kroz 20 epoha

Linijski grafikoni prate trening i validacionu gresku, kao i validacioni F1 za spam posle svake epohe.

LSTM tok treniranja kroz 20 epoha



Najvisi validacioni spam F1 je 0.9635 u 18. epohi.

Pad F1 u poslednje dve epohe pokazuje da vise epoha ne mora automatski dati bolji model.

Jupyter kod: LSTM tok treniranja

X-osa dolazi iz kolone epoch, a y-vrednosti iz train_loss, validation_loss i validation_spam_f1.

```
python

# Jedan red istorije nastaje posle svake epohe.
epochs = history_df["epoch"]
fig, axes = plt.subplots(1, 2, figsize=(13, 5))

axes[0].plot(epochs, history_df["train_loss"],
             marker="o", color="tomato", label="trening greska")
axes[0].plot(epochs, history_df["validation_loss"],
             marker="o", color="steelblue", label="validaciona greska")
axes[1].plot(epochs, history_df["validation_spam_f1"],
             marker="o", color="seagreen", label="validacioni spam F1")

axes[0].set_xlabel("Broj epohe")
axes[1].set_xlabel("Broj epohe")
plt.tight_layout()
```


Istorija se popunjava posle svake od 20 epoha, bez koriscenja test skupa.

Evaluacija i izbor hiperparametara

- Trening skup služi za učenje parametara modela.
- Validacioni skup služi za izbor hiperparametara i najboljeg kandidata.
- Test skup se koristi tek na kraju, za finalnu procenu.
- Glavne metrike: precision, recall i F1 za spam klasu.

Model	Skup	Precision	Recall	F1
TF-IDF + LogReg	Validacija	0.99	0.99	0.99
TF-IDF + LogReg	Test	0.99	0.96	0.97
LSTM	Validacija	0.98	0.91	0.95
LSTM	Test	0.94	0.90	0.92

Poredjenje rezultata



Zaključak: TF-IDF je stabilniji i brzi; LSTM takodje radi dobro, ali je složeniji i osjetljiviji na hiperparametre.

Jupyter kod: poredjenje rezultata

Visine stubova dolaze iz precision, recall i F1 rezultata finalnih evaluacija oba modela.

```
python

# Finalne spam metrike iz svesaka 03 i 05.
metrics = ["spam_precision", "spam_recall", "spam_f1"]
results = pd.DataFrame(
    [[0.99, 0.99, 0.99], [0.99, 0.96, 0.97],
     [0.98, 0.91, 0.95], [0.94, 0.90, 0.92]],
    index=["TF-IDF validacija", "TF-IDF test",
           "LSTM validacija", "LSTM test"],
    columns=metrics,
)
ax = results[metrics].plot(
    kind="bar", ylim=(0, 1),
    color=["tomato", "seagreen", "steelblue"],
)
```

Svaka grupa stubova predstavlja jedan model i skup: validacioni ili test.

Zaključak i literatura

- Ling-Spam je nebalansiran tekstualni skup, pa se fokus stavlja na spam metrike.
- TF-IDF + Logistic Regression daje najbolji odnos jednostavnosti, brzine i kvaliteta.
- LSTM pokazuje kako se tekst može tretirati kao sekvenca reci.
- Test skup je sacuvan za kraj, kako bi finalna procena bila postena.

Literatura:

Ling-Spam corpus; scikit-learn dokumentacija; PyTorch dokumentacija; materijali sa vezbi.